

Beyin Tümörü Görüntülerinin İyileştirilmesi ve Analizi

Örüntü Tanıma

Hafsa Nijad

Bilgisayar Mühendisliği Bölümü

ÇANKIRI KARATEKİN

ÜNİVERSİTESİ

Çankırı

200905200@ogrenci.karatekin.edu.tr

Özet— Bu çalışmada, beyin tümörü görüntülerinin işlenmesi, analiz edilmesi ve sınıflandırılması hedeflenmiştir. Görüntü kalitesini artırmak için Normalizasyon, Histogram Eşitleme, Gaussian Smoothing, Median Filtre ve Wavelet Dönüşümü gibi görüntü işleme teknikleri uygulanarak gürültü azaltılmış ve detayların görünürlüğü artırılmıştır. Ardından, makine öğrenmesi ve derin öğrenme tabanlı yöntemler kullanılarak sınıflandırma gerçekleştirilmiştir. Random Forest, K-Nearest Neighbors (KNN), Logistic Regression, Support Vector Machines (SVM), XGBoost ve Convolutional Neural Networks (CNN) algoritmaları kullanılmış; XGBoost %93.10 doğruluk oranı ile en yüksek performansı sergilerken, CNN algoritması %86.21 doğruluk oranına ulaşmıştır. Elde edilen sonuçlar, kullanılan yöntemlerin beyin tümörlerini yüksek doğrulukla sınıflandırabildiğini ve erken teşhis için etkili bir çözüm sunduğunu göstermektedir.

Keywords— *Brain Tumor, Image Processing, Machine Learning, Normalization, Histogram Equalization, Gaussian Smoothing, Median Filter, Wavelet Transform, Convolutional Neural Network (CNN), Histogram of Oriented Gradients (HOG), Random Forest, Logistic Regression, K-Nearest Neighbors (KNN), Support Vector Machines (SVM), XGBoost, Medical Image Analysis, Feature Extraction, Classification*

I. GİRİŞ

Beyin tümörleri, dünya genelinde yüksek ölüm oranlarına ve yaşam kalitesinin düşmesine neden olan ciddi bir sağlık sorunudur. Erken teşhis, hastalığın ilerlemesini yavaşlatmada ve tedavi sürecinin başarısını artırmada kritik bir öneme sahiptir. Manyetik Rezonans Görüntüleme (MRI) gibi modern görüntüleme teknikleri, beyin tümörlerinin detaylı incelenmesini mümkün kılmaktadır. Ancak, ham MRI görüntüleri genellikle gürültü içerir ve düşük kontrast seviyelerine sahiptir; bu durum teşhis sürecini daha karmaşık hale getirmektedir.

Bu çalışmada, MRI görüntülerinden oluşan bir veri seti kullanılmış ve beş sınıf üzerine odaklanılmıştır: NORMAL T1, Astrocitoma T1, Carcinoma T1, Ependimoma T1 ve Ganglioglioma T1. NORMAL T1, sağlıklı bireylerin beyin görüntülerini içeren referans bir grubu temsil ederken, Astrocitoma T1 astrosit hücrelerinden kaynaklanan yavaş büyüyen tümörleri temsil etmektedir. Carcinoma T1, kötü huylu ve agresif karsinomları içerirken, Ependimoma T1 ependimal hücrelerden kaynaklanan tümörleri temsil etmektedir. Ganglioglioma T1 ise hem glial hem de nöronal hücrelerden oluşan karmaşık bir tümör türüdür.

Bu proje, ilgili sınıfların detaylı analizini yaparak, beyin tümörlerinin doğru sınıflandırılmasını ve teşhis süreçlerinin iyileştirilmesini amaçlamaktadır. Görüntü işleme ve makine öğrenmesi tabanlı geliştirilen yöntemler, tıbbi teşhis süreçlerini daha etkili ve hızlı hale getirerek sağlık alanına önemli bir katkı sağlamayı hedeflemektedir.

II. LİTERATÜR TARAMASI

Beyin tümörü görüntülerinin iyileştirilmesi, analizi ve sınıflandırılması üzerine yapılan çalışmalar, son yıllarda makine öğrenmesi ve görüntü işleme tekniklerinin entegrasyonu sayesinde büyük bir ivme kazanmıştır. Normalizasyon, Histogram Eşitleme, Gaussian Smoothing, Median Filtre ve Wavelet Dönüşümü gibi geleneksel yöntemler, tıbbi görüntülerin kalitesini artırarak detayların daha görünür hale gelmesini sağlamaktadır. Bu yöntemler, gürültünün azaltılması, kontrastın iyileştirilmesi ve detayların netleştirilmesinde kritik bir rol oynar. Özellikle Wavelet Dönüşümü, çoklu çözünürlük analizine olanak tanıyarak görüntülerin genel yapısını ve detaylarını eş zamanlı olarak inceleme imkanı sunar [1, 2].

Makine öğrenmesi yöntemleri, bu iyileştirilmiş görüntüler üzerinde çalışarak otomatik ve yüksek doğrulukta analizler sağlamaktadır. CNN (Convolutional Neural Network) gibi derin öğrenme algoritmaları, karmaşık veri yapıları üzerinde çalışarak etkili sınıflandırma gerçekleştirmektedir [3]. Rastgele Orman algoritması, karar ağaçları temelli yapıyla sınıflandırma işlemlerinde etkili bir yöntemdir [4]. KNN (K-En Yakın Komşu), özellikle küçük veri kümelerinde hızlı ve etkili sınıflandırmalar sağlamak için kullanılmaktadır [5]. Lojistik Regresyon, veriler arasındaki doğrusal ilişkileri analiz ederek sınıflandırma işlemleri gerçekleştirmektedir [6]. HOG (Histogram of Oriented Gradients) yöntemi ise kenar ve şekil özelliklerini çıkararak görüntüdeki detaylı analizlerde sıkça kullanılmaktadır [7].


Literatürde, tıbbi görüntülerin segmentasyonu ve sınıflandırılması üzerine birçok yöntem geliştirilmiştir. Destek Vektör Makineleri (SVM), karmaşık veri yapıları üzerinde sınıflandırma yaparken yüksek doğruluk oranları sağlamaktadır [8]. XGBoost algoritması ise ağaç temelli yapıyla hızlı ve güçlü bir sınıflandırma çözümü sunar ve birçok tıbbi görüntü analizinde etkili bir yöntem olarak kullanılmaktadır [9]. Büyük veri kümeleri üzerinde yapılan çalışmalar, modellerin genelleme yeteneklerini artırmış ve sınıflandırma doğruluğunu önemli ölçüde iyileştirmiştir [10].

Görüntü işleme tekniklerinin tıbbi teşhis süreçlerine entegrasyonu, yalnızca sınıflandırma doğruluğunu artırmakla kalmayıp, aynı zamanda doktorların zaman kazanmasına da olanak tanımaktadır [11]. Özellikle, tıbbi teşhis sistemlerinin derin öğrenme modelleriyle desteklenmesi, karmaşık yapılar üzerinde daha hassas analizler yapılmasını sağlamaktadır [12]. Bunun yanında, veri artırma (Data Augmentation) gibi yöntemler, eğitim verisinin çeşitliliğini artırarak modellerin performansını olumlu yönde etkilemektedir [13].

Literatürdeki birçok çalışma, geleneksel görüntü işleme yöntemlerinin makine öğrenmesi algoritmalarıyla birleştirmede sinerji yarattığını ve tıbbi görüntü analizi için etkili çözümler sunduğunu göstermektedir [14]. Gelecekte, daha geniş veri kümelerinin yanı sıra hibrit modellerin geliştirilmesiyle bu yöntemlerin klinik uygulamalarda daha yaygın bir şekilde kullanılması beklenmektedir [15].

III. YÖNTEMLER

Bu çalışmada, beyin tümörü görüntülerinin işlenmesi, analiz edilmesi ve sınıflandırılması amacıyla modern görüntü işleme teknikleri ve makine öğrenmesi algoritmaları bir araya getirilmiştir. Proje, MRI görüntülerindeki gürültüyü azaltmak, kontrastı iyileştirmek ve detayları daha net hale getirmek için bir dizi yöntem sunmaktadır. MRI görüntüleri genellikle düşük kontrastlı ve yüksek düzeyde gürültü içerdiğinden, bu sorunları gidermek için güçlü görüntü işleme teknikleri uygulanmıştır. Projenin ilk aşamasında, Wavelet Transform, Histogram Eşitleme, Median Filter, Gaussian Smoothing ve Normalization gibi geleneksel yöntemler kullanılmıştır. Bu yöntemler, ham MRI görüntülerindeki zayıf detayların daha görünür hale getirilmesine olanak sağlamıştır. Wavelet Transform, görüntüyü farklı detay seviyelerine ayırarak genel yapı ve küçük ölçekli özelliklerin ayrı ayrı incelenmesini sağlamıştır. Histogram Eşitleme, düşük kontrastlı alanlardaki detayları artırarak görüntüyü analiz için daha uygun hale getirmiştir. Median Filter, özellikle tuz ve biber gürültüsünü gidermek için kullanılmış ve bu süreçte kenar detaylarını koruyarak etkili bir gürültü azaltımı sağlamıştır. Gaussian Smoothing, görüntülerin daha pürüzsüz hale getirilmesini sağlarken yüksek frekanslı gürültüyü azaltmıştır. Son olarak, Normalization, piksel değerlerini bir aralığa ölçeklendirerek görüntülerin tutarlı bir şekilde analiz edilmesine olanak tanımıştır.



Bu iyileştirme aşamasında elde edilen sonuçlar, MRI görüntülerinin analizi için sağlam bir temel oluşturmuştur. Görüntülerin her bir aşamada nasıl değiştiği, iyileştirme sürecinin etkisini açıkça göstermektedir. Görüntü işleme aşamalarından elde edilen görsellerde, orijinal görüntüden başlayarak her bir adımda detayların daha net hale geldiği ve gürültünün önemli ölçüde azaldığı gözlemlenmiştir. Örneğin, Wavelet Transform, görüntünün genel yapısını korurken küçük ölçekli gürültüyü azaltmıştır. Histogram Eşitleme ve Gaussian Smoothing, kontrastı artırarak detayları daha belirgin hale getirmiştir.

Makine öğrenmesi aşamasında, bu iyileştirilmiş görüntüler üzerinde özellik çıkarımı yapılmıştır. Özellikle Histogram of Oriented Gradients (HOG) yöntemi, kenar ve

şekil detaylarını analiz ederek her bir görüntünün karakteristik özelliklerini ortaya çıkarmıştır. Çıkarılan bu özellikler, altı farklı makine öğrenmesi algoritması ile sınıflandırılmıştır: HOG-KNN, Random Forest, Logistic Regression, Support Vector Machine (SVM), XGBoost ve Convolutional Neural Network (CNN). Her bir algoritma, farklı yaklaşımlarla veri analizi yapmış ve MRI görüntülerindeki tümör türlerini doğru bir şekilde sınıflandırmayı amaçlamıştır.

Test sonuçları, XGBoost ve CNN algoritmalarının diğer yöntemlere göre daha yüksek performans gösterdiğini ortaya koymuştur. XGBoost, ağaç tabanlı yapısıyla karmaşık veri kümelerinde yüksek doğruluk sağlamıştır. CNN, derin öğrenme temelli bir algoritma olarak, büyük veri kümelerinde detaylı özellik çıkarımı ve sınıflandırma aşamalarında etkili olmuştur. Random Forest, karar ağaçları yapısını kullanarak dengeli bir doğruluk sağlamış, Logistic Regression ise daha basit veri kümelerinde etkili olmuştur. KNN ve SVM, diğer yöntemlere kıyasla daha sınırlı performans göstermiştir ancak bazı senaryolarda kullanışlı olabilecek hız ve sadelik sunmuştur.

XGBoost ve CNN algoritmalarının sınıflandırma süreçlerinde en etkili algoritmalar olduğunu göstermektedir. Random Forest, yüksek özgüllük oranı ve dengeli performansı ile dikkat çekerken, Logistic Regression nispeten daha basit veri kümelerinde etkili sonuçlar sağlamıştır. HOG-KNN ve SVM algoritmaları, daha sınırlı performans sunmasına rağmen veri analizi süreçlerinde katkı sağlamıştır.

Bu proje, geleneksel görüntü işleme teknikleri ile makine öğrenmesi algoritmalarını birleştirerek MRI görüntülerinden detaylı özellikler çıkarmış ve sınıflandırma doğruluğunu önemli ölçüde artırmıştır. Elde edilen bu sonuçlar, tıbbi görüntülerin analizi ve erken teşhis süreçlerinde kullanılabilecek yenilikçi bir çözüm sunmaktadır. Projenin gelecekte daha büyük veri setleri ve farklı görüntüleme teknikleri üzerinde test edilmesi, klinik uygulamalarda daha geniş bir kullanım potansiyeli ortaya koyacaktır.

IV. BİLİMSEL ANLATIM VE PERFORMANS DEĞERLENDİRMESİ

Bu proje kapsamında, beyin tümörü görüntülerinin işlenmesi ve sınıflandırılması amacıyla altı farklı makine öğrenmesi algoritması ve çeşitli görüntü işleme teknikleri bir arada kullanılmıştır. İlk aşamada, MRI görüntüleri üzerinde Wavelet Transform, Histogram Eşitleme, Median Filter, Gaussian Smoothing ve Normalization gibi geleneksel görüntü işleme yöntemleri uygulanmıştır. Bu yöntemler, görüntülerin kalitesini artırarak sınıflandırma için daha uygun hale getirilmesini sağlamıştır. Görüntü işleme aşaması, veri üzerindeki gürültüyü azaltmak ve detayların daha net bir şekilde görünmesini sağlamak amacıyla kritik bir adım olmuştur.

İkinci aşamada, görüntülerden çıkarılan özellikler makine öğrenmesi ve derin öğrenme algoritmaları ile analiz edilmiştir. Altı farklı algoritma kullanılmıştır: HOG-KNN, Random Forest, Logistic Regression, SVM, XGBoost ve CNN. Her bir algoritma, beyin tümörü türlerini doğru bir şekilde sınıflandırmak amacıyla farklı yaklaşımlar sunmuştur. HOG-KNN, kenar ve şekil özelliklerine odaklanarak benzerlik tabanlı hızlı bir sınıflandırma sağlamıştır. Logistic Regression, doğrusal ilişkilere dayalı bir model sunmuş ve veri kümesindeki doğrusal yapıları başarıyla analiz etmiştir. Random Forest, karar ağaçları yapısıyla yüksek doğruluk ve

dengeli sonuçlar sağlamıştır. SVM, çekirdek fonksiyonları sayesinde doğrusal olmayan veri yapıları üzerinde etkili sonuçlar sunarken, XGBoost ağaç tabanlı yapısıyla en yüksek doğruluk oranını sağlamıştır. CNN ise büyük veri kümelerinde otomatik özellik çıkarımı yaparak sınıflandırma sürecinde güçlü bir performans göstermiştir.

Aşağıdaki tablo, kullanılan algoritmaların özelliklerini, avantajlarını ve dezavantajlarını özetlemektedir:

Algorithm	Özellikler	Avantajlar	Dezavantajlar
HOG-KNN	Kenar ve şekil özelliklerini analiz ederek benzerlik tabanlı sınıflandırma yapar.	Hızlı ve basit; küçük veri kümelerinde etkilidir.	Büyük veri kümelerinde yüksek hesaplama maliyeti; diğer algoritmalara göre daha düşük doğruluk..
Random Forest	Karar ağaçlarına dayanır ve birden fazla ağaç kullanarak sınıflandırmayı güçlendirir.	Büyük veri kümelerinde hızlıdır; dengesiz veri setlerinde dengeli sonuçlar sunar.	Çok karmaşık veri setlerinde genelleme kabiliyeti sınırlı olabilir.
Logistic Regression	Doğrusal ilişkilere dayanır ve sınıflandırma problemlerinde basit bir model sunar.	Hesaplama açısından etkilidir ve küçük veri kümelerinde hızlı çalışır.	Doğrusal olmayan veri setlerinde etkisizdir; karmaşık veri yapılarında sınırlı performans.
SVM	Çekirdek fonksiyonları kullanarak doğrusal olmayan sınıflandırmalar yapar.	Küçük ve orta büyüklükteki veri setlerinde yüksek doğruluk sağlar.	Büyük veri kümelerinde yüksek hesaplama maliyeti.
XGBoost	Ağaç tabanlı öğrenme algoritması olup gradyan artırma tekniğini kullanır.	Hızlıdır; genelleme kapasitesi yüksektir ve büyük veri kümelerinde etkili çalışır.	Parametre ayarı karmaşıktır; fazla öğrenmeye (overfitting) yatkın olabilir.
CNN	Derin öğrenme tabanlı bir algoritma olup otomatik özellik çıkarımı ve sınıflandırma yapar.	Büyük veri setlerinde yüksek doğruluk sağlar; karmaşık veri yapıları üzerinde çalışabilir.	Eğitim süreci uzundur ve hesaplama açısından maliyetlidir; büyük miktarda veri gerektirir.

Sonuç olarak, bu algoritmaların her biri, beyin tümörü sınıflandırmasında önemli bir rol oynamıştır. XGBoost ve CNN, doğruluk açısından en yüksek performansı gösterirken, Random Forest ve Logistic Regression dengeli ve etkili sonuçlar sunmuştur. HOG-KNN ve SVM algoritmaları daha düşük doğruluk sağlamasına rağmen, belirli veri setlerinde ve hızlı analizlerde kullanılabilir potansiyele sahiptir. Bu çalışma, geleneksel görüntü işleme teknikleri ve makine öğrenmesi algoritmalarını bir araya getirerek MRI görüntülerinden detaylı özellik çıkarımı yapmış ve sınıflandırma sürecinde etkili sonuçlar elde etmiştir. Bu yaklaşımın, tıbbi teşhis süreçlerinde doğruluğu artıracığı ve klinik uygulamalarda geniş bir kullanım potansiyeli sunacağı düşünülmektedir.

V. SONUÇ

Bu çalışmada, farklı makine öğrenimi algoritmaları kullanılarak beyin tümörü görüntülerinin sınıflandırma performansı değerlendirilmiştir. İncelenen algoritmalar arasında Logistic Regression, Random Forest, K-Nearest Neighbors (KNN), Support Vector Machine (SVM), XGBoost ve Convolutional Neural Network (CNN) yer almaktadır. Performans ölçütleri doğruluk, duyarlılık, özgüllük ve karışıklık matrisi analizlerine dayanmaktadır.

Logistic Regression algoritması, doğrusal sınıflandırmaya dayalı bir yöntem olarak veri setindeki sınıfları başarılı bir şekilde ayırt etmiştir. Algoritmanın doğruluk oranı %75.86, duyarlılık oranı %54.00 ve özgüllük oranı %93.33 olarak hesaplanmıştır. Bu sonuçlar, Logistic Regression'ın düşük karmaşıklığa sahip veri kümelerinde etkili bir yöntem olduğunu göstermektedir. Ancak doğrusal olmayan ilişkilerin bulunduğu veri setlerinde sınırlamalar yaşayabilir.

Random Forest algoritması, karar ağaçları yapısını kullanarak dengeli bir performans sergilemiştir. Algoritmanın doğruluk oranı %82.76, duyarlılık oranı %49.90 ve özgüllük oranı %92.42 olarak hesaplanmıştır. Karışıklık matrisi analizine göre, bu algoritma belirli sınıflarda oldukça başarılı bir şekilde sınıflandırma yapmış, ancak düşük temsil edilen sınıflarda performansı düşmüştür.

K-Nearest Neighbors (KNN) algoritması, hızlı ve basit bir yöntem olarak sınıflandırma sürecinde kullanılmıştır. Algoritmanın doğruluk oranı %51.72, duyarlılık oranı %22.00 ve özgüllük oranı %90.00 olarak hesaplanmıştır. Düşük duyarlılık oranına rağmen, bu algoritma küçük veri kümelerinde hızlı analizler için faydalı olabilir.

Support Vector Machine (SVM) algoritması, doğrusal olmayan ilişkileri modelleme kabiliyetiyle öne çıkmıştır. Algoritmanın doğruluk oranı %72.41, duyarlılık oranı %35.71 ve özgüllük oranı %90.10 olarak hesaplanmıştır. Karışıklık matrisi analizine göre, SVM belirli sınıflarda yüksek doğruluk sunmuş ancak daha karmaşık veri kümelerinde sınırlamalar göstermiştir.






XGBoost algoritması, kullanılan yöntemler arasında en yüksek performansı göstermiştir. Doğruluk oranı %93.10, duyarlılık oranı %73.33 ve özgüllük oranı %96.85 olarak hesaplanmıştır. Bu algoritma, özellikle büyük veri kümelerinde genelleme kapasitesinin yüksek olduğunu göstermiştir.



Convolutional Neural Network (CNN) algoritması, derin öğrenme tabanlı bir yöntem olarak etkili sonuçlar sunmuştur. Algoritmanın doğruluk oranı %86.21, duyarlılık oranı %56.57 ve özgüllük oranı %90.00 olarak hesaplanmıştır. CNN, özellik çıkarımı ve sınıflandırma işlemlerini otomatik olarak gerçekleştirme yeteneğiyle öne çıkmıştır.

Sonuçların özetlendiği tablo aşağıda sunulmuştur:

Algorithm	Accuracy (%)	Sensitivity (%)	Specificity (%)
HOG-KNN	51.72	22.00	90.00
Random Forest	82.76	49.90	92.42
Logistic Regression	75.86	54.00	93.33
SVM	72.41	35.71	90.10
XGBoost	93.10	73.33	96.85
CNN	86.21	56.57	90.00

Bu sonuçlar, XGBoost ve CNN algoritmalarının sınıflandırma sürecinde en iyi performansı sunduğunu göstermektedir. Logistic Regression ve Random Forest algoritmaları dengeli bir performans sunarken, SVM ve KNN daha sınırlı performans göstermiştir. Çalışma, kullanılan yöntemlerin verimli bir şekilde beyin tümörü sınıflandırması yapabileceğini ve bu tür yaklaşımların tıbbi teşhis süreçlerinde önemli katkılar sağlayabileceğini ortaya koymaktadır.





KAYNAKLAR

- [1] M. Petrou and P. Gacia, *Image Processing: Dealing with Texture*, Wiley,2006.
- [2] A. K. Jain, *Fundamentals of Digital Image Processing*, Prentice-Hall, 1989.
- [3] S. Mallat, *A Wavelet Tour of Signal Processing*, Academic Press, 1999.
- [4] Y. Meyer, *Wavelets: Algorithms and Applications*, SIAM, 1993.
- [5] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521,pp.436–444,2015.
- [6] J. MacQueen, "Some methods for classification and analysis of multivariate observations," *Proc. Fifth Berkeley Symp. Math. Statist. Probab.*,1967.
- [7] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32,2001.
- [8] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967.
- [9] D. Hosmer and S. Lemeshow, *Applied Logistic Regression*, Wiley, 2000.
- [10] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection,"*Proc.CVPR*,2005.
- [11] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition,"*Proc.CVPR*,2016.
- [12] J. Quinlan, "C4.5:Programs for Machine Learning," Morgan Kaufmann,1993.
- [13] H. Greenspan, B. van Ginneken, and R. M. Summers, "Deep learning in medical imaging: Overview and future promise," *Medical Image Analysis*,vol.35,pp.1–19,2017.
- [14] M. Litjens et al., "A survey on deep learning in medical image analysis," *Medical Image Analysis*, vol. 42, pp. 60–88, 2017.
- [15] A. Esteva et al., "Deep learning-enabled medical computer vision," *Nature Medicine*, vol. 25, pp. 24–29, 2019.